




Politecnico
di Bari

Project Work – Digital Business

25
Maggio
2026



ChatBot AI Multimodale

Benchmarking Tecnologico

Roberto Carriero

PANORAMICA DEL BENCHMARKING

Frontend

React, input testuale, immagini e audio

Backend

FastAPI, normalizzazione e orchestrazione AI

RAG e LLM

BGE-M3, ChromaDB, Qwen3 via Ollama

Operatività

Dashboard React, ticket, KPI e deploy

FRONTEND UTENTE

Obiettivo: Realizzare un'interfaccia conversazionale responsive

- **Chat Conversazionale:** Un solo punto di accesso per domande, suggerimenti e risposte con fonti.
- **Upload Multimodale:** Immagini e audio vengono allegati nella stessa esperienza utente.
- **Esperienza Operativa:** La UI deve essere chiara, leggibile e intuitiva.

TECNOLOGIE



React



Streamlit



Gradio



BACKEND E API LAYER

Obiettivo: Coordinare chat, RAG, moduli multimodali, ticket e logging

- **Orchestrazione:** Il backend gestisce routing, retrieval, generazione, escalation e salvataggio dati.
- **API Documentate:** Gli endpoint devono essere testabili e documentati.
- **Ecosistema AI:** Python riduce la complessità di integrazione con embedding, OCR, audio e LLM locali.

TECNOLOGIE



FastAPI



Flask



Django



KNOWLEDGE BASE E DATA LAYER

Obiettivo: Gestire sorgenti, metadati, conversazioni, ticket e KPI in modo tracciabile

- **Knowledge Base:** I dati restano in JSON/CSV normalizzati, versionabili e facili da aggiornare.
- **Schema RAG:** *search_text* per il retrieval, *answer_text* per la risposta, metadata per filtro e fonte.
- **Persistenza:** PostgreSQL conserva chat, messaggi, ticket, feedback e log di valutazione.

TECNOLOGIE



JSON/CSV ★★★★★



PostgreSQL ★★★★★



Django ★★★☆☆

EMBEDDING E VECTOR DATABASE

Obiettivo: Recuperare contenuti dalla Knowledge Base e ridurre le allucinazioni

- **Embedding Semantici:** BGE-M3 trasforma *search_text* in vettori multilingua adatti al retrieval.
- **Vector Store:** ChromaDB indicizza documenti, embedding e metadati in modo rapido.
- **Metadata Filtering:** Il retrieval viene ristretto per dominio, fonte, collezione e qualità del dato.

TECNOLOGIE



BGE-M3



MiniLM



Qwen3



TECNOLOGIE



ChromaDB



Qdrant



FAISS



LARGE LANGUAGE MODEL (LLM)

Obiettivo: Generare risposte naturali ma vincolate al contesto recuperato dal RAG

- **Risposta Contestuale:** Il modello non sostituisce la KB, ma formula la risposta usando le fonti recuperate.
- **Costo Zero a Token:** Il modello viene servito localmente tramite Ollama, senza API commerciali.
- **Controllo:** Prompt e soglie di escalation limitano risposte non supportate o ambigue.

TECNOLOGIE



Qwen3 8B ★★★★★



Llama 3 ★★★★★



Mistral ★★★★★

PIPELINE MULTIMODALE

Obiettivo: Unificare testo, audio e immagini in una richiesta unica gestita dal backend

- **Audio:** Whisper trascrive i vocali e produce testo interrogabile dal RAG.
- **OCR:** Tesseract estrae testo da cartelli, locandine, avvisi e screenshot leggibili.
- **Visione:** CLIP riconosce monumenti e luoghi tramite visual similarity su una galleria di riferimento.

TECNOLOGIE



Whisper ★★★★★



Tesseract ★★★★★



CLIP ★★★★★

DASHBOARD, TICKETING E KPI

Obiettivo: Trasformare le interazioni in richieste operative e risultati misurabili

- **Ticket Automatico:** Ogni escalation conserva domanda, chat history, fonti recuperate e motivo.
- **Dashboard React:** L'operatore vede stato, priorità, dominio, contesto RAG e note.
- **Valutazione KPI:** CSV e script Python per calcolare KPI primari, quantificare le metriche e valutare le prestazioni.

TECNOLOGIE



React



Streamlit



JSON/CSV



VERSIONING E DEPLOYMENT

Obiettivo: Garantire collaborazione, riproducibilità e demo live stabile

- **Versioning:** Git e GitHub permettono branch, pull request e tracciabilità del lavoro.
- **Deployment:** Docker Compose avvia frontend, backend, PostgreSQL e ChromaDB in modo riproducibile.

TECNOLOGIE



Git

★★★★★



GitHub

★★★★★



Docker

★★★★★