



Multimodal AI Agent for Customer Care

Project Work Digital Business - TP Italia x Politecnico di Bari

ANALISI DEI KPI PER LE METRICHE DI VALUTAZIONE

L'obiettivo di questa attività è individuare e definire gli indicatori chiave di prestazione, cioè i KPI, necessari a valutare il corretto funzionamento dell'assistente virtuale durante i Giochi del Mediterraneo Taranto 2026. L'analisi si concentra su metriche misurabili nel sistema, utilizzando i dati a disposizione per conversazioni, ticketing, risultati del retrieval e feedback degli utenti.

L'assistente virtuale deve essere valutato anche rispetto alla velocità del sistema, alla capacità di recuperare informazioni corrette dalla knowledge base e all'impatto sul lavoro degli operatori umani. Per tale motivo, i KPI sono stati organizzati in tre macroaree: Qualità Informativa, Performance Tecnica e Impatto Operativo.

1. QUALITÀ INFORMATIVA

In quest'area controlliamo che l'assistente comprenda correttamente la richiesta dell'utente e riesca a recuperare le informazioni più pertinenti all'interno della knowledge base.

Vengono mantenuti KPI misurabili attraverso un benchmark di domande di test. Per ogni domanda si definiscono in anticipo il dominio corretto e i documenti attesi. Il sistema viene poi valutato confrontando le sue predizioni con questi valori di riferimento.

- **Domain Accuracy:** verifica se il bot capisce l'argomento principale della domanda e la indirizza verso il dominio corretto. Ad esempio, se l'utente chiede informazioni sui biglietti, il sistema deve classificare la richiesta nel dominio *Ticketing* e non in quello relativo ai alla storia dei giochi o alle venue.
- **Recall@5:** misura se il sistema riesce a recuperare almeno un documento corretto tra i primi cinque risultati restituiti dal motore RAG. Se il documento giusto non viene recuperato, anche il modello linguistico avrà difficoltà a generare una risposta corretta.

- **Precision@5:** misura quanti dei primi cinque documenti recuperati sono effettivamente pertinenti alla domanda dell'utente. Una buona precisione riduce il rumore informativo e migliora la qualità del contesto passato al modello linguistico.
- **MRR (Mean Reciprocal Rank):** valuta quanto in alto compare il primo documento corretto tra i risultati recuperati. Se il documento giusto è al primo posto, il valore è massimo. Se compare più in basso, il punteggio diminuisce.
- **Source Coverage Rate:** misura la percentuale di risposte che riportano almeno una fonte o un riferimento recuperato dalla knowledge base.

2. PERFORMANCE TECNICA

In quest'area misuriamo la fluidità e l'affidabilità tecnica del sistema, per assicurarci che l'utente non sperimenti attese eccessive o errori durante l'utilizzo della chat da telefono o computer. Le metriche di performance vengono raccolte automaticamente dal backend, registrando i tempi delle varie fasi della pipeline, ovvero ricezione della richiesta, eventuale trascrizione audio, eventuale OCR dell'immagine, retrieval, generazione della risposta e invio al frontend.

- **Average Latency:** misura il tempo medio che passa da quando l'utente invia una richiesta a quando riceve la risposta finale. La metrica deve essere calcolata in modalità end-to-end, includendo tutte le fasi necessarie alla produzione della risposta. Per le richieste testuali il tempo include retrieval e generazione, mentre per audio e immagini include anche trascrizione o riconoscimento del contenuto visivo.
- **p95 Latency:** misura il tempo entro cui rientra il 95% delle richieste. Permette di capire se il sistema resta utilizzabile anche quando alcune richieste sono più lente della media. Questo KPI è particolarmente utile nei momenti di maggiore traffico, ad esempio durante eventi sportivi importanti o nelle fasce orarie di maggiore affluenza.
- **Error Rate:** misura la percentuale di richieste che falliscono rispetto al totale delle richieste ricevute. Un errore può essere dovuto a problemi del backend, mancata risposta del modello, errore nel retrieval, fallimento dell'OCR, errore nella trascrizione audio o problemi nella comunicazione con il frontend.
- **ASR-OCR Success Rate:** misura la percentuale di input vocali o immagini elaborati correttamente dal sistema. Nel caso dell'audio, valuta se la trascrizione viene prodotta senza errori tecnici, mentre nel caso delle immagini, valuta se il sistema riesce a estrarre testo utile o informazioni utilizzabili tramite OCR o analisi visiva.

3. IMPATTO OPERATIVO

Quest'area misura il valore aziendale del sistema, cioè quanto il chatbot riesce a ridurre il carico sugli operatori umani e a gestire in autonomia le richieste informative più frequenti.

- **Containment Rate:** misura la percentuale di conversazioni risolte dal bot senza apertura di ticket e senza intervento dell'operatore. Un containment rate elevato significa minore carico operativo per il personale e maggiore efficienza del servizio.
- **Escalation Rate:** misura la percentuale di conversazioni che vengono trasferite a un operatore umano tramite apertura di ticket. Serve a capire quanto spesso il sistema ricorre al supporto umano e se il volume di escalation è sostenibile.
- **Feedback Score:** misura la soddisfazione dell'utente attraverso feedback espliciti. È una metrica semplice da raccogliere e molto utile in ottica business, perché mostra se il servizio viene percepito come utile, chiaro e affidabile.

TABELLA RIASSUNTIVA DEI KPI

Macroarea	Nome	Misura	Fonte
Qualità Informativa	Domain Accuracy	Capacità di classificare correttamente il dominio della domanda	Retrieval
Qualità Informativa	Recall@5	Capacità di recuperare almeno un documento corretto tra i primi 5 risultati	Retrieval
Qualità Informativa	Precision@5	Quanti documenti tra i primi 5 recuperati sono davvero pertinenti	Retrieval
Qualità Informativa	MRR	Quanto in alto compare il primo documento corretto nei risultati	Retrieval
Qualità Informativa	Source Coverage Rate	Percentuale di risposte supportate da almeno una fonte della knowledge base	Retrieval
Performance Tecnica	Average Latency	Tempo medio di risposta end-to-end del sistema	Backend
Performance Tecnica	p95 Latency	Tempo entro cui rientra il 95% delle richieste	Backend
Performance Tecnica	Error Rate	Percentuale di richieste fallite rispetto al totale	Backend

Performance Tecnica	ASR-OCR Success Rate	Percentuale di audio e immagini elaborati correttamente	Backend
Impatto Operativo	Containment Rate	Percentuale di conversazioni risolte senza operatore	Database
Impatto Operativo	Escalation Rate	Percentuale di conversazioni trasferite a un operatore	Database
Impatto Operativo	Feedback Score	Soddisfazione dell'utente dopo l'interazione	Database