



Multimodal AI Agent for Customer Care

Project Work Digital Business - TP Italia x Politecnico di Bari

VALUTAZIONE METRICHE DI PERFORMANCE E KPI

Al termine della fase di sviluppo è stato testato l'intero flusso operativo del sistema **T.A.L.O.S.**, con l'obiettivo di raccogliere dati quantitativi per il calcolo delle **metriche di prestazione**. Tali metriche sono collegate ai **Key Performance Indicator (KPI)** individuati in precedenza, rapportando il comportamento del sistema agli obiettivi di business del progetto.

Testing End-to-End Automatizzato

La valutazione del ChatBot è stata condotta tramite un **benchmark dedicato** che misura le prestazioni del sistema RAG, del backend e dell'escalation verso operatore umano.

Il test è stato eseguito utilizzando un **dataset testuale** composto da **130 campioni**, costruito per simulare richieste realistiche degli utenti finali. I casi coprono le **principali aree informative** gestite dal sistema, come informazioni generali sull'evento, sedi di gara, calendario, biglietteria. Inoltre, il dataset include **richieste in più lingue e casi critici**, come problemi di accessibilità, richieste di operatori umani o non risolvibili in autonomia dal bot.

Per ogni caso di test sono stati definiti alcune **feature di riferimento** (campi del dataset), ovvero il dominio atteso della domanda, i documenti pertinenti della KB, la lingua della richiesta, il feedback atteso e l'eventuale apertura simulata di un ticket di customer-care per richieste specifiche.

Per l'effettivo testing è stato realizzato uno **script Python** per automatizzare il processo. Lo script **legge i record** di test dal dataset JSONL, **invia le richieste** al backend tramite le API esistenti e **misura/calcola i valori** necessari.

Al termine, lo script **aggrega i risultati** e **genera un file CSV**, al percorso `eval/outputs/results.csv`, con i KPI calcolati. Tale file contiene, per ogni metrica, il **nome**, la **descrizione**, il **valore** ottenuto e l'**unità di misura**, come riportato nella tabella seguente.

KPI	Descrizione	Valore + Unità
Domain Accuracy	Capacità del sistema di classificare correttamente il dominio informativo della richiesta utente	92,62%
Recall@5	Capacità del sistema di includere almeno un documento corretto tra i primi cinque risultati recuperati	79,51%
Precision@5	Quota media di documenti effettivamente pertinenti tra i primi cinque risultati recuperati	74,75%
Mean Reciprocal Rank	Posizione media del primo documento corretto, calcolata tramite reciprocal rank	72,04%
Source Coverage Rate	Percentuale di risposte supportate da almeno una fonte della knowledge base	79,07%
Average Latency	Tempo medio di risposta end-to-end del sistema	5,65 secondi
p95 Latency	Tempo massimo entro cui rientra il 95% delle richieste	10,92 secondi
Error Rate	Percentuale di richieste fallite rispetto al totale delle richieste elaborate	0,77%
Escalation Rate	Percentuale di conversazioni trasferite o trasformate in ticket per l'operatore	6,20%
Containment Rate	Percentuale di conversazioni risolte senza intervento dell'operatore	93,80%
Feedback Score	Soddisfazione media dell'utente sui messaggi valutati	92,73%

Discussione dei Risultati

La **Domain Accuracy** pari al 92,62% indica che il ChatBot è in grado di classificare correttamente la maggior parte delle richieste in riferimento al dominio corretto. Questo dato è rilevante perché la classificazione del dominio condiziona la fase successiva di retrieval e la qualità della risposta finale.

Il **Recall@5** pari a 0,7951 mostra che nella maggior parte dei casi almeno un documento corretto viene recuperato tra i primi cinque risultati. Questo indica che la KB viene interrogata in modo efficace e che il sistema riesce a intercettare le fonti utili per rispondere alla domanda dell'utente.

Il valore del **Mean Reciprocal Rank**, pari a 0,7204, conferma che il primo documento pertinente tende a comparire in posizioni alte della lista dei risultati. Questa condizione è utile in un sistema RAG perché i documenti posizionati in alto hanno più influenza sulla risposta.

Il valore della **Precision@5**, pari a 0,7475 indica che il sistema recupera cinque documenti per ogni domanda e la risposta corretta utilizza buona parte dei documenti rilevanti. Quelli esclusi

sono comunque semanticamente vicini. Tale valore assume significato nel trade-off tra copertura informativa e selezione del numero dei documenti da recuperare.

Il **Source Coverage Rate** pari al 79,07% indica che la maggior parte delle risposte generate è accompagnata da almeno una fonte della knowledge base. Questo è un risultato importante perché dimostra che il sistema tende a produrre risposte basate su documenti recuperati.

Dal punto di vista tecnico, la **latenza media** tra la domanda e la risposta è risultata pari a circa 5,65 secondi, con una **p95 latency** di circa 10,92 secondi. Questi valori sono ottimi per una pipeline che comprende query planning, retrieval semantico, generazione tramite modello LLM, persistenza dei messaggi nel database e gestione dei feedback. Il valore p95 indica che la maggior parte delle richieste (il 95%) rimane entro la soglia accettabile per una risposta automatica. L'**Error Rate** pari allo 0,77% evidenzia inoltre una buona stabilità del sistema.

Per quanto riguarda l'impatto operativo, il sistema ha ottenuto un **Containment Rate** pari al 93,80% e un **Escalation Rate** pari al 6,20%. Questo significa che la maggior parte delle conversazioni è stata gestita automaticamente dal ChatBot, mentre per una quota ridotta è stato aperto un ticket verso l'operatore.

Infine, il **Feedback Score** pari al 92,73% mostra una soddisfazione elevata degli utenti sui casi valutati.

Nel complesso, il benchmark conferma che il sistema è in grado di fornire **supporto automatizzato esaustivo** e orientato alla **riduzione del carico sull'operatore**. I margini di miglioramento riguardano l'aumento della Precision@5 e la riduzione della latenza. Tali aspetti potrebbero essere affrontati negli sviluppi futuri tramite ottimizzazione della KB e reranking mirato dei risultati RAG, oltre all'utilizzo di LLM con tempi di risposta inferiori.

In riepilogo:

KPI + Valore	Significato
Domain Accuracy: 93%	Il sistema riconosce correttamente quasi tutti i domini delle domande mediante il query planning con LLM
Recall@5: 80%	In circa l'80% dei casi, almeno una fonte pertinente compare nei primi cinque documenti recuperati
Precision@5: 75%	Il sistema restituisce cinque documenti e in maggioranza sono strettamente rilevanti rispetto alla domanda
Mean Reciprocal Rank: 72%	Il primo documento utile tende a comparire nelle prime posizioni del ranking, compensando la Precision@5 più bassa
Source Coverage Rate: 79%	La maggior parte delle risposte generate dal sistema è associata a fonti informative (la quota restante riguarda richieste non coperte dalla KB e messaggi operativi)

Average Latency: 6 secondi	Il tempo medio è coerente con una pipeline composta da query planning, retrieval, generazione tramite LLM e persistenza nel database
p95 Latency: 11 secondi	Il 95% delle richieste viene gestito entro circa 11 secondi, con margine di ottimizzazione in futuro
Error Rate: 0,8%	Il tasso di errore è molto basso, ovvero circa una richiesta fallita ogni 130
Escalation Rate: 6%	Il sistema coinvolge l'operatore solo in una minoranza dei casi
Containment Rate: 94%	La maggioranza delle conversazioni viene gestita autonomamente dal ChatBot, riducendo di molto il carico sul customer-care umano
Feedback Score: 93%	La soddisfazione dell'utente è elevata ed è coerente con una buona copertura informativa